590개 공정 변수에서, 어디부터 봐야 할까?

UCI SECOM 기반 공정 데이터 품질 검증 및 문제 정의

1,567
SAMPLES

590
SENSOR FEATURES

104
FAIL SAMPLES

6.64%
FAIL RATE

Missing ≠ 0

초기에는 결측값을 0으로 대체했으나, 실제 데이터에 0값이 200,005개 존재해 **"실제 측정값 0"과 "원래 Missing"이 섞이며 통계 결과가 왜곡**됨을 확인했습니다. 따라서 0 대치를 폐기하고 Raw Data부터 다시 분석했습니다.

- 전체 Missing Rate: 4.52%
- 일부 Sensor Missing Rate: 90% 이상
- 실제 Zero 값: 200,005개

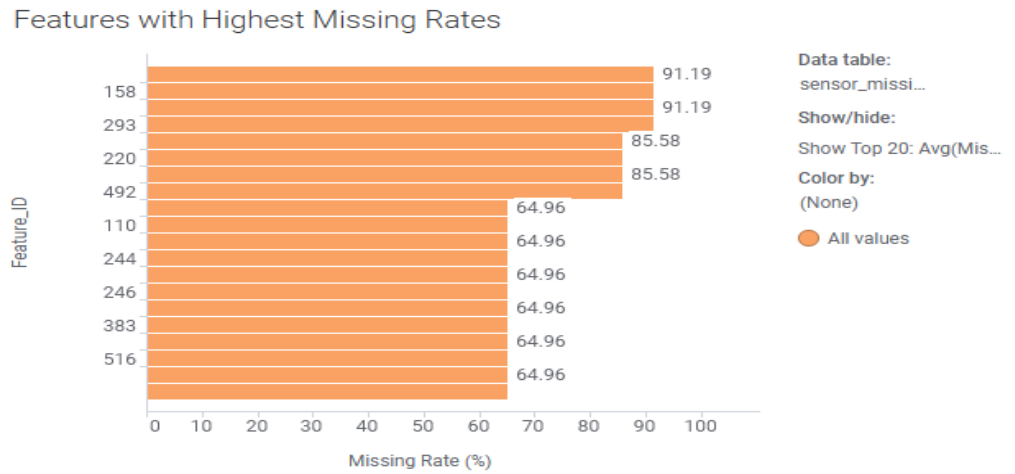
반도체 공정에서는 수많은 계측 변수가 동시에 축적되지만,
모든 변수에 동일한 관리 자원을 투입하기는 어렵습니다.

본 프로젝트에서는 590개 익명 공정 변수 중 불량 예측에 기여하는 후보를 선별하고, **엔지니어가 우선 확인할 관리 변수를 압축**하고자 했습니다.

💡"불량을 얼마나 잘 맞히는가?"

↓

"590개 변수 중 어디부터 확인해야 하는가?"



전체 결측률은 4.52%였지만 일부 Sensor에 결측이 집중됨

불균형 데이터를 Leakage 없이 검증하다

Missing 처리 → 불균형 대응 → XGBoost → 독립 Test

Train / Test Split

Median + Indicator
- 단순 Median 대치
- 원래 Missing 여부는 보존

SMOTENC
- Fail Minority Oversampling
- Train Fold에만 적용 (Leakage 차단)

XGBoost
- 비선형·다변량 관계 학습

5-Fold CV
- Accuracy 대신 AP, F1 사용 (Fail 6.6% 불균형 구조 대비)

Feature Selection 유지 💡

ANOVA 기반 선택(25~400개) 비교 결과, 590개 전체 사용 시 AP(0.1987)가 가장 높음. 단변량 차이가 작아도 다변량 모델에서 활용될 가능성을 고려해 전체 변수를 유지했습니다.

OOF Average Precision (성능 개선 흐름)



Independent Test →

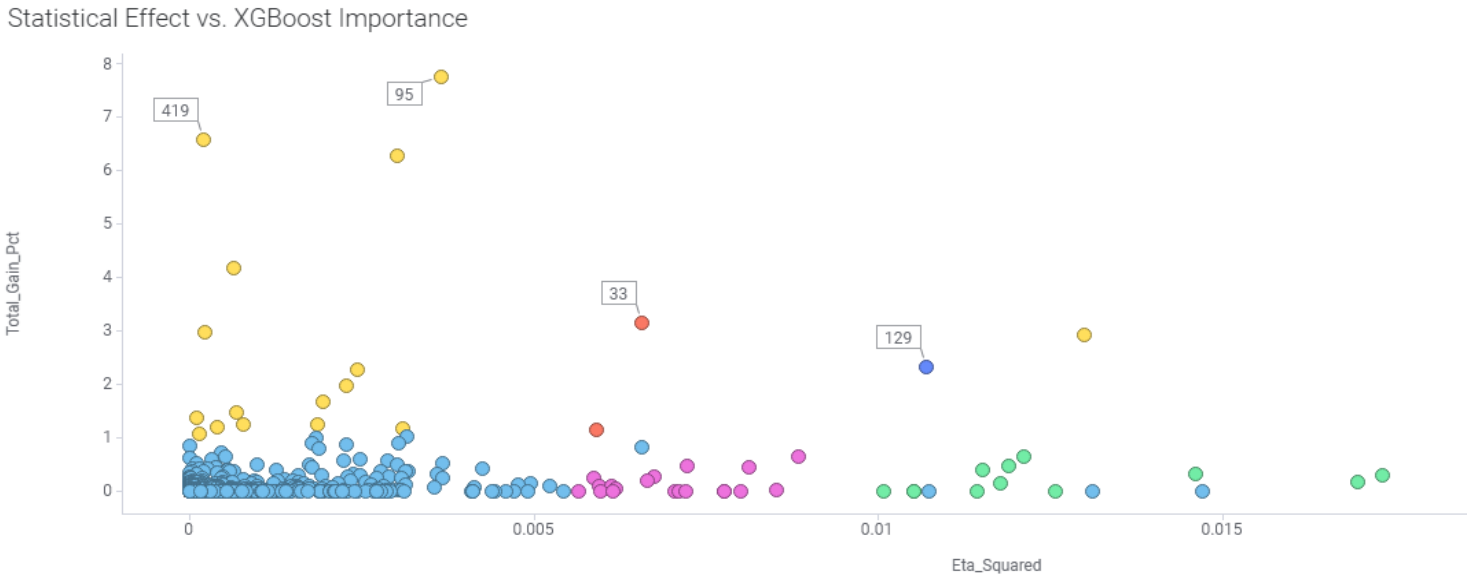
Test AP (일반화 한계 확인)

0.1213

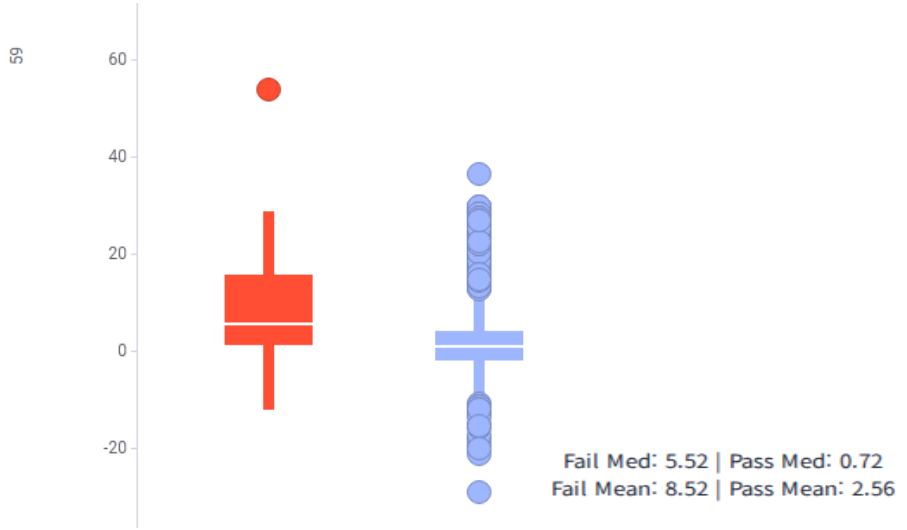
Prevalence: 6.69% | Threshold: 0.28 | F1: 0.207 (TP:6, FP:31)

통계 × ML × 안정성으로 관리 후보 압축

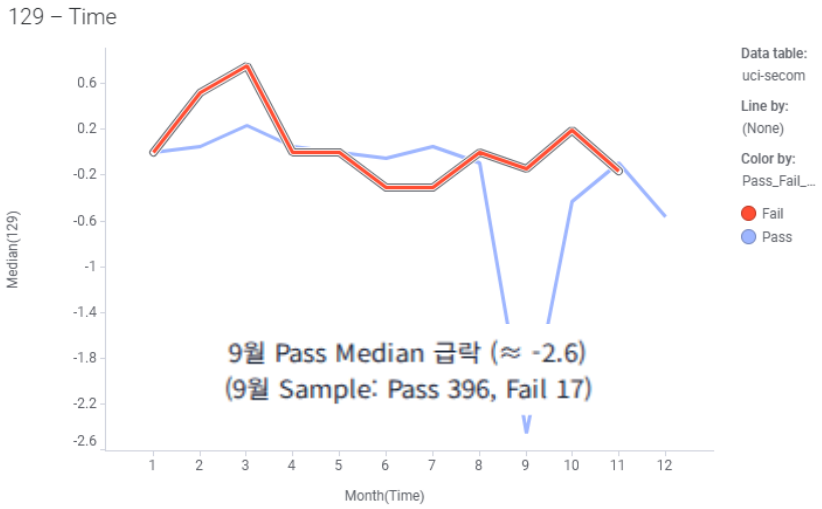
Feature Importance를 원인이 아닌 "검토 우선순위"로 해석



Sensor	Evidence	Interpretation (검토 우선순위 사유)
59	Multi-evidence	통계·ML·CV 모두 지지하는 최우선 후보
33	Multi-evidence	단변량 효과는 작지만 ML에서 안정적
129	Multi + Time	특정 시기 공정 상태 변화 혼재 가능성 (시간축 확인)
419	Stable ML-only	통계 비유의, ML에서는 5 Fold 모두 최상위
95	Stable ML-only	Step-like 구조를 보인 안정적 ML 후보



Sensor 59: Fail 분포가 높은 값 방향으로 이동했지만, 두 Class의 분포 중첩도 존재. 단일 Sensor만으로 판별은 불가함.



Sensor 129: 전체 Pass/Fail 차이를 불량 원인으로 단정하지 않고, 9월의 공정 상태 변화가 혼재했을 가능성을 파악함.